حسن كاظمى طهراني

9629041

گزارش فاز دوم پروژه بازیابی اطلاعات

در این فاز ما به جای استفاده از مکان کلمات برای رتبه بندی، از شاخص tfidf استفاده کردیم. قسمت هایی از کد که تغییر کرده است شامل:

محاسبه tf و idf و tfidf برای هر کلمه در هر سند در مرحله indexing.

محاسبه طول بردار tfidf که بعدا برای محاسبه شباهت کسینوسی لازم می شود.

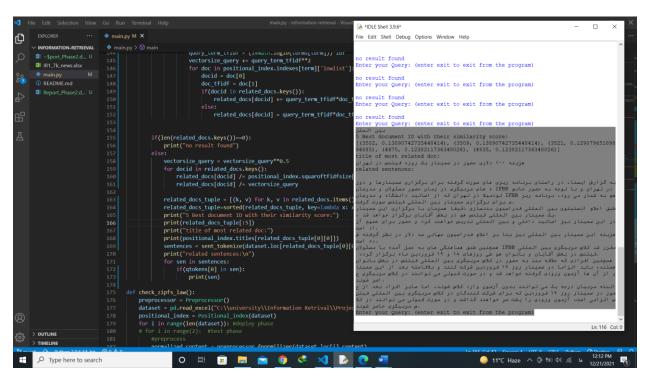
مرتب سازی سند های هر کلمه بر اساس tfidf برای درست کردن championlist.

تغییر در پیدا کردن اسناد که در این فاز به کمک محاسبه بردار tfidf و محاسبه شباهت کسینوسی انجام پذیرفته است.

گزارش های خواسته شده: ( برای مقایسه دقیقا همان کلمات مورد استفاده در فاز 1 استفاده شده است )

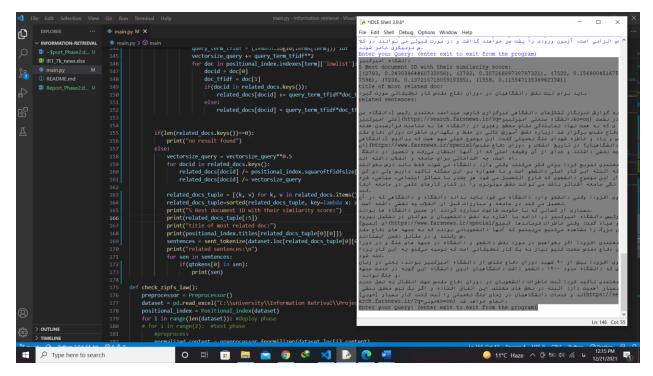
# 1- پاسخ به پرسمان در حالت های زیر:

الف ) یک پرسمان از کلمات ساده و متداول تک کلمه ای: (بین الملل)



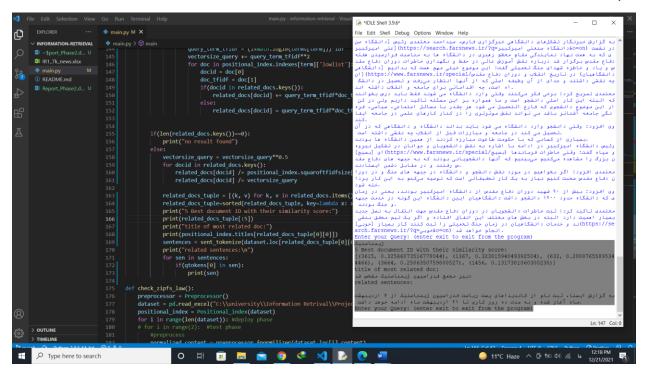
بله مرتبط است و در این فاز اسنادی پیدا می شود که تعداد بیشتری کلمه منحصر به فرد از کوئری را دارا می باشند. این خبر واکشی شده مربوط به یک سمینار بین المللی با حضور مربی های بین المللی می باشد.

ب یک پرسمان از عبارات ساده و متداول چند کلمه ای ( دانشگاه امیرکبیر)



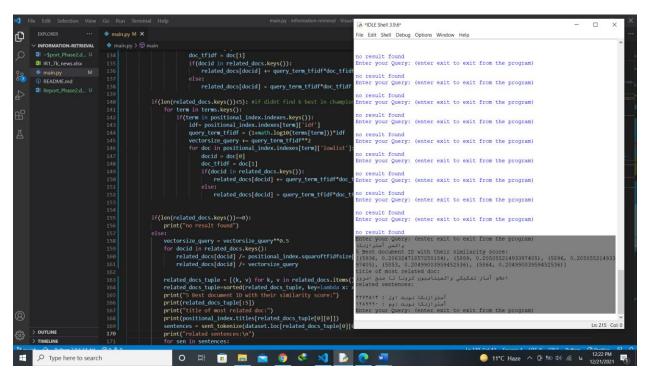
بله مرتبط است. خبر حاوی تعداد زیادی جمله حاوی "دانشگاه امیر کبیر" می باشد و خبر و اکشی شده مربوط به سخنر انی رئیس دانشگاه امیر کبیر می باشد که کاملا مرتبط می باشد.

# پ) یک پرسمان دشوار و کم تکرار تک کلمه ای ( ژیمناستیک )



بله مرتبط است. خبر کاملا مربوط به رشته ژیمناستیک می باشد که دبیر فدر اسیون آن در خبر تغییر یافته است. گرچه این خبر تنها یک بار کلمه ژیمناستیک آمده است ولی به دلیل idf بالای این کلمه این خبر مرتبط شده است.

# ت) یک پرسمان دشوار و کم تکرار چند کلمه ای (واکسن آسترازنکا)



بله مرتبط است. خبر مربوط به امار واکسیناسیون کرونا می باشد که نوبت های واکسن آستر از نکا نیز در متن خبر آمده است.

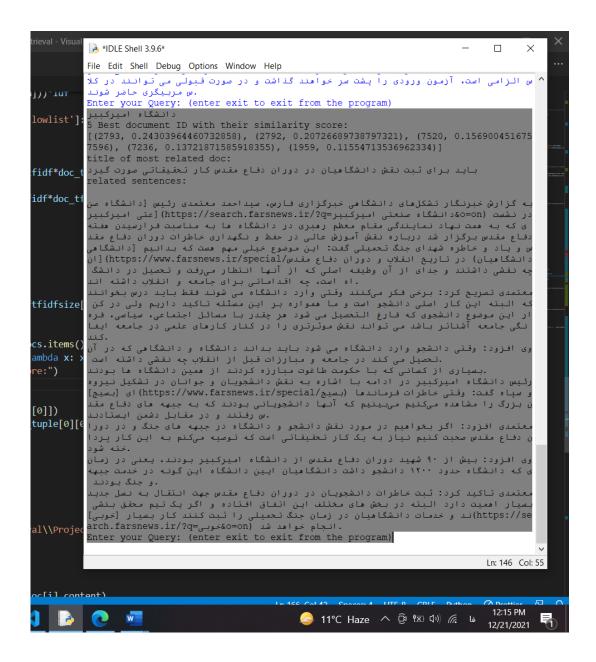
#### 2- مقايسه با فاز 1:

(<u></u>

## در فاز 1:

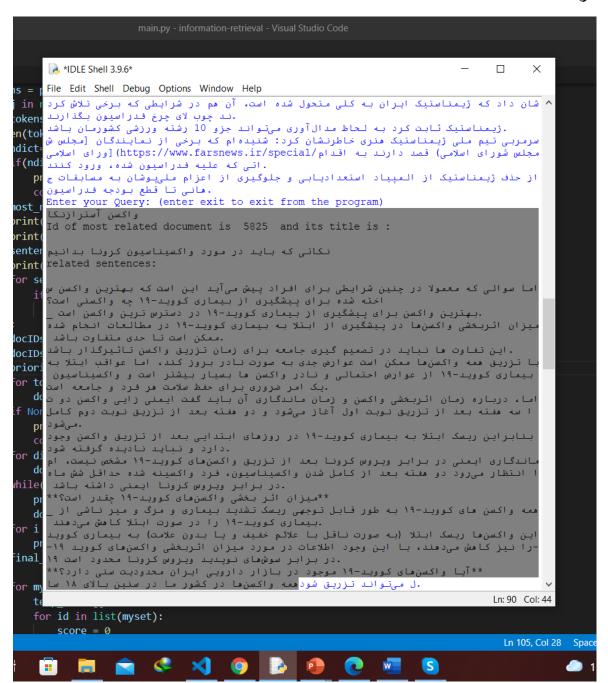
```
*IDLE Shell 3.9.6*
                                                                                                                           tokens = [ File Edit Shell Debug Options Window Help
for j in Enter your Query: (enter exit to exit from the program)
     بين الملل tokens
if(len(tol Id of most related document is 410 and its title is:
     ndict=
              اعلام آخرین اقدامات تراکتور برای بازشدن پنجره/ احتمال استفاده از بازیکنان جدید بر
     ابر گلگهر if(ndi
          pr related sentences:
     مشاور باشگاه تراکتور گفت: با توجه به اختلاف ساعت بین ایران و آمریکای جنوبی، مدیرع _most
امل و امور بین الملل باشگاه، معمولا شبها با وکلای این دو بازیکن صحبت کرده و پیگیری print
              .های لازم را انجام میدهند
     print(Enter your Query: (enter exit to exit from the program)
     دانشگاه امیرکبیر senter
              Id of most related document is 2792 and its title is:
     print(
     for se
               امروز محیط دانشگاههای ما عرصه دفاع مقدس است
              related sentences:
     به گزارش خبرنگار تشکل های دانشگاهی خبرگزاری فارس حجت الاسلام میراحمدی مسئول نهاد ن docID:
مایندگی مقام معظم رهبری در دانشگاه امیرکبیر در نشستی که به همت نهاد نمایندگی مقا
              می سیده می سنام رسیری در دانشگاه ها به مناسبت فرارسیدن هفته دفاع مقدس برگزار شد، گفت: نکت
ه ای که باید به آن توجه ویژه کرد این است که انقلاب اسلامی ایران یک انقلاب مردم صحور
است و در همه عرصه ها به خصوص در عرصه های دفاعی و اصنیتی هم مردمی است و اگر مردم
     docIDs
     priori
     for to
               بودند نمی وانست در برابر تهاجم دشمنان و ابرقدرتها که همه دست به دست هم داده بو
          .دند، دوام بیاورد dc
     سئول نهاد رهبری در دانشگاه امیرکبیر گفت: ما در دوران دفاع مقدس حدود ۲۲۶ هزار شه
               .ید دادیم این شهدا از طیف های مختلف مردم هستند
              یک بخشی از آنها هم از دانشجویان بودند و بیش از چند هزار نفر شهید دانشگاهی داریم
که حدود نود شهید از دانشگاه امیرکبیر هستند که در عملیاتهای مختلف به شهادت رسیدند
     for di
     وی تصریح کرد: بخشی از این شهدای دانشجو، دانشجویانی بودند که از لحاظ درسی وضعیت غ while(
داشتند و که اگر امروز می بو (o=on&خوبی=https://search.farsnews.ir/?q)یلیی [خوبی] pr
دند بدون تردید جزو اعضای فیئت علمی دانشگاه بودند pr
               سئول نهاد رهبری در دانشگاه امیرکبیر گفت: ما به برکت این شهدا امروز حمله نظامی ن
           do
          داریم، آمروز دیگر کسی جرات حمله به سرزمین آیران را ندآرد i
پراحمدی اظهار داشت: امروز جنگ تمام نشده و رزمندگان ما هنوز حضور دارند امروز محی
لا دانشگاه ما عرصه دفاع مقدس است برای آن آرمانهای بالاتری که همه ما باید به آن توج pl
     for i
     ُ آُنُ <sub>تو</sub>چ final
.ه کنیم
              Enter your Query: (enter exit to exit from the program)
     for m
                                                                                                                            Ln: 21 Col: 0
           16
           for id in list(myset):
                                                                                                                             Ln 105, Col 28 Spaces: 4
```

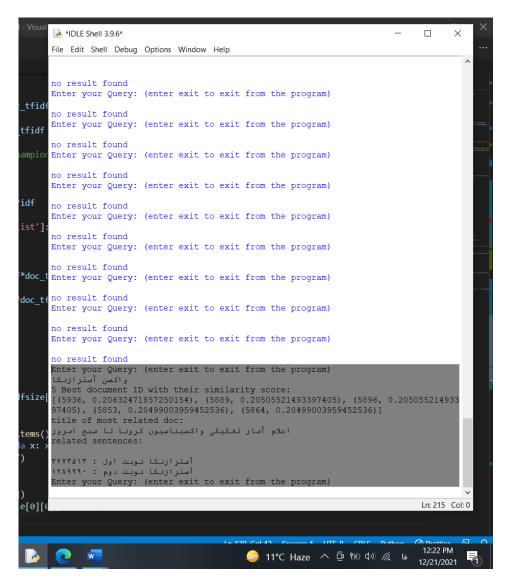
در فاز2:



هر دو سند واکشی شده مرتبط می باشد. اما نکته حائز اهمیت این می باشد که در سند واکشی شده در موتور جستجو فاز 2، کلمه ی دانشگاه و امیر کبیر بدون توجه به مکان بسیار زیاد تکرار شده است و به همین علت رتبه این سند بالا آمده است. اما در فاز 1، کمتر این کلمات تکرار شده است اما جایگاهشان در بیشتر مواقع در کنار هم می باشد زیرا که در فاز 1، رتبه بندی براساس جایگاه کلمات نیز می باشد. به همین علت سند های و اکشی شده متفاوت می باشد اما هر دو سند مرتبط است.

### فاز 1:





هر دو سند مرتبط است. اما سند واکشی شده در فاز 2 مرتبط تر می باشد. در فاز 1 سندی در رابطه با واکسیناسون کرونا واکشی شده که به واکسن آستر از نکا نیز اشاره ای شده است. اما در فاز دوم به کلمه آستر از نکا که دار ای idf بیشتری می باشد اهمیت زیادی داده شده و خبر نوبت دهی این واکسن خاص واکشی شده است زیرا که در فاز دوم رتبه بندی به tfidf توجه بیشتری دارد گرچه کلمه آستر از نکا دقیقا بعد از واکسن نیامده است.